

Predikcija cene nekretnina u Kaliforniji

Ana Petrović

Elektrotehnički fakultet, Univerzitet u Beogradu

1 Uvod

Ideja rada je da na osnovu niza podataka/obeležja predvidi cenu nekretnina u Kaliforniji. Ideja je preuzeta iz rada "*Analysis and Forecasting of California Housing*", autora Yucong Chen, koji je 2022. godine predstavljen na *International Conference on Management Science and Industrial Engineering*, održanoj na Tajlandu. Rad se može pronaći na [linku](#).

Podaci korišćeni prilikom izrade rada se mogu naći na sledećem [linku](#).


2 Analiza i pretprocesiranje podataka

Baza se sastoji od 20640 primera sa po 9 obeležja i jednom ciljnom promenljivom koja predstavlja cenu nekretnine.

longitude	latitude	housing_median_age	total_rooms	total_bedrooms	population	households	median_income	median_house_value	ocean_proximity
-122.23	37.88	41.0	880.0	129.0	322.0	126.0	8.3252	452600.0	NEAR BAY
-122.22	37.86	21.0	7099.0	1106.0	2401.0	1138.0	8.3014	358500.0	NEAR BAY
-122.24	37.85	52.0	1467.0	190.0	496.0	177.0	7.2574	352100.0	NEAR BAY
-122.25	37.85	52.0	1274.0	235.0	558.0	219.0	5.6431	341300.0	NEAR BAY
-122.25	37.85	52.0	1627.0	280.0	565.0	259.0	3.8462	342200.0	NEAR BAY
-122.25	37.85	52.0	919.0	213.0	413.0	193.0	4.0368	269700.0	NEAR BAY
-122.25	37.84	52.0	2535.0	489.0	1094.0	514.0	3.6591	299200.0	NEAR BAY
-122.25	37.84	52.0	3104.0	687.0	1157.0	647.0	3.1200	241400.0	NEAR BAY
-122.26	37.84	42.0	2555.0	665.0	1206.0	595.0	2.0804	226700.0	NEAR BAY
-122.25	37.84	52.0	3549.0	707.0	1551.0	714.0	3.6912	261100.0	NEAR BAY

Slika 1: Prikaz podataka

Da bismo bolje uočili zavisnost između obeležja koja će biti bitna prilikom pretprocesiranja, napravićemo korelacionu matricu.




Slika 2: Korelaciona matrica

Nakon provere, vidimo da kod 207 primera fale podaci za obeležje *total bedrooms*. Na osnovu korelacione matrice, primećujemo da je najveći koeficijent korelacije sa obeležjem *households*. Za svaki od 207 primera pronađeno je 20 primera koji imaju najslabije vrednosti obeležja *households* i izostavljeni podatak za *total bedrooms* je zamenjen medijanom vrednosti pomenutih 20 primera.

	Predictor	NaN Count
0	longitude	0
1	latitude	0
2	housing_median_age	0
3	total_rooms	0
4	total_bedrooms	207
5	population	0
6	households	0
7	median_income	0
8	median_house_value	0
9	ocean_proximity	0


Slika 3: Prikaz izostavljenih podataka

Takođe, iz kovarijacione matrice vidimo da najveću zavisnost sa izlazom ima obeležje *median income*, što se može videti i na slici 4 a). Lokacija ima veliki uticaj na cenu nekretnine što vidimo po koeficijentu korelacije *longitude* i *latitude*. Na slici 4 b) je ova zavisnost i vizuelno prikazana, gde se lepo oslikava obala Kalifornije. Jačina plavih tačkica govori o ceni nekretnina u tom delu.




Slika 4: Zavisnost cene nekretnine i obeležja

Obeležje *ocean proximity* predstavlja kategoričku promenljivu sa 5 mogućih vrednosti. Problem koji se javlja je taj da neke od kategorija obuhvataju previše veliki opseg lokacija, pri čemu im se gubi informativnost. Da bi se ovo ispravilo, vrednosti *NEAR OCEAN* i *<1H OCEAN* ćemo podeliti na po 2 kategorije, pa će tako severni deo Kalifornije u kome su niže cene nekretnina biti odvojen od ostatka i dobiti svoje 2 kategorije *NEAR OCEAN NORTH* i *<1H OCEAN NORTH*. Rezultati ove izmene vidljivi su na boxplot-ovima na slici ispod.



Slika 5: Adaptacija obeležja *ocean proximity*


Posednja stvar koju treba uraditi pre nego što podaci budu spremni za primenu modela je normalizacija. Kako deo obeležja nema normalnu raspodelu, već su jasno uočljivi repovi na jednu stranu, primenićemo logaritamsku transformaciju.



Slika 6: Normalizacija podataka

3 Ridge regresija

Prilikom primene Ridge regresije, vidimo da je model previše jednostavan da bi zadovoljio potrebe ovog problema. Prilikom promene parametra α , ne vidimo promene na validacionom i trening skupu, što nam govori o nedovoljnom treniranju. Rešenje za ovaj problem je dodati još obeležja ili uzeti kompleksniji model.




Slika 7: Ridge regresija

Za parametar α usvojena je vrenost 1. U poređenju sa ostala 2 modela, Ridge regresija se pokazala kao najlošija sa $RMSE = 0.33078$.

4 Random Forest

Kod Random Forest modela kao validaciona tehnika korišćen je *out-of-bag*. Kao hiperparametri uzeti su *broj stabala*, *dubina* i *broj obeležja*, dok je za evaluaciju korišćen R^2 skor.




Slika 8: Random Forest - izbor hiperparametara

Korišćenjem da su $n\ estimators = 250$, $max\ depth = 14$, $max\ features = 6$, dobijamo da je $RMSE=0.23283$.

5 Gradient Boosting

Poslednji model koji je korišćen je Gradient Boosting. Korišćena je 5-ostruka unakrsna validacija, dok su za hiperparametre razmratani *broj iteracija*, *dubina* i *stopa učenja*.



Slika 9: Gradient Boosting - izbor hiperparametara

Korišćenjem da su $n\ estimators = 250$, $max\ depth = 10$, $learning\ rate = 0.07$, dobijamo da je $RMSE=0.22165$.

6 Rezultati i zaključak

Prvi korak bio je pretprocesiranje dobijenih podataka, kako bismo dobili bazu koju je moguće proslediti modelima. Kao i u pomenutom radu, obrađena su 3 modela za predikciju cene nekretnine: Ridge regresija, Random Forest i Gradient Boosting. Za svaki od modela nađeni su adekvatni hiperparametri i na pomoću njih određene finalne predikcije. Za evaluaciju modela korišćen je koren srednje kvadratne greške. Kao što se može videti u tabeli ispod, *RMSE* kod sva 3 modela se ne razlikuje previše u odnosu na podatke iz rada "*Analysis and Forecasting of California Housing*".

Za svaki model korišćena je višestruka unakrsna validacija za dobijanje hiperparametara, pri čemu su kriterijui bili R^2 skor i *RMSE*.

Model	RMSE	RMSE (iz rada)
Ridge	0.33078	0.37310
Random Forest	0.23283	0.29093
Gradient Boosting	0.22165	0.29484

Tabela 1: Upoređivanje rezultata

Do malog neslaganja u rezultatima moglo je doći na dva mesta, prilikom pretprocesiranja, kada je potrebno dopuniti nedostajuće podatke i prilikom nalaženja hiperparametara.